Лабораторная работа №6
Кластеризация
(максимум за эту работу – 5 баллов)

По данной работе необходимо подготовить отчет в формате блокнота Jupyter Notebook (.ipynb) либо в текстовом виде (.pdf).

Основная часть (4 балла)

В этом задании дан датасет с синтетическими (специально сгенерированными) данными.

Легенда

Учёный решил провести кластеризацию некоторого множества звёзд по их расположению на карте звёздного неба. Кластер звёзд – это набор звёзд (точек) на карте, лежащий внутри круга некоторого радиуса. Каждая звезда принадлежит ровно одному кластеру. Под расстоянием понимается расстояние Евклида.

Описание входных данных

В файле хранятся данные о звёздах **трёх** кластеров. В каждой строке записана информация о расположении на карте одной звезды: сначала координата *x*, затем координата *y*. Значения даны в условных единицах.

Задание

1. Загрузите данные.
2. Поскольку данные синтетические и специально подготовленные, то никакую предварительную обработку проводить не нужно. Однако, проверьте правильность загрузки данных и их тип.
3. Из библиотеки sklearn.cluster возьмите алгоритм кластеризации KMeans. Постройте модель. Количество кластеров нужно задать исходя из описания входных данных. Начальный выбор центроидов – случайный. Получите разбиение на кластеры.
4. Постройте точечный график, на котором выведите все звёзды (по одной оси – x-координаты звёзд, по другой – y-координаты, цвет точек соответствует кластеру).
5. Метрикой качества для задачи кластеризации является «силуэт». Посчитайте значение этого показателя для полученного разбиения на кластеры (функция silhouette_score из библиотеки sklearn.metrics).
6. Попробуйте выполнить разбиение на другое количество кластеров (например, 5). Посмотрите, как изменился показатель силуэт.

Дополнительное задание (+1 балл)

Реализуйте алгоритм k-means самостоятельно (то есть напишите свою реализацию этого метода). Реализация должна решать данную конкретную задачу (то есть не нужно стараться сделать полный аналог библиотечной функции, не нужно никаких параметров). Сравните результат своей реализации со стандартной.